

Análisis de la variación de la precipitación en la Sierra y Selva del Perú

Cubas Quispe Andrea S.¹, Soto Zelada Brenda N.¹, Tuppia Paitan Gabriel F.¹

¹Departamento de Física y Meteorología, Facultad de Ciencias, Universidad Nacional Agraria La Molina, Lima, Perú

Abstract

La presente investigación evalúa la variación espacio-temporal de la precipitación en la Sierra y Selva del Perú durante el período 1981–2014, integrando información observacional del SENAMHI con los productos ERA5 y CHIRPS. Dado que los registros presentaban vacíos, se aplicó un proceso de limpieza, completación de series y comparativo en python. Posteriormente, todas las series fueron mensualizadas con el fin de homogenizar las escalas temporales y facilitar los análisis comparativos.

Con los datos ajustados, se elaboraron series de tiempo, diagrama de cajas (Boxplots) e Histogramas. Este análisis reveló sesgos sistemáticos: ERA5 sobreestima significativamente la precipitación en las estaciones andinas y no reproduce su marcada estacionalidad seca, mientras que CHIRPS y ERA5 subestiman la magnitud, especialmente de eventos extremos, en la Amazonía. Posteriormente se evaluaron modelos predictivos Regresión Lineal AR, Random Forest y LSTM para el pronóstico mensual a 12 meses.

Los resultados mostraron que, en la Sierra, los modelos Random Forest y Regresión Lineal AR logran alta precisión ($R^2 0.910$) aprovechando una estacionalidad bien definida. En contraste, en la Selva, donde la variabilidad es mayor, la Regresión Lineal AR fue el enfoque más robusto, aunque el modelo LSTM destacó por preservar cualitativamente mejor la ciclicidad climática a largo plazo. Este estudio proporciona una caracterización detallada de los patrones pluviométricos y evalúa herramientas de modelado, ofreciendo insumos valiosos para la gestión hídrica y la planificación climática en la región andino-amazónica.

Keywords: Variabilidad espacio-temporal; Precipitación; CHIRPS; ERA5; SENAMHI; Random Forest; LSTM; Perú; Sierra; Selva

1. Introducción

La región andina y amazónica del Perú conforma uno de los sistemas hidroclimáticos más complejos del planeta, debido a la interacción entre la cordillera de los Andes, la cuenca amazónica y las corrientes oceánicas del Pacífico tropical. Esta configuración produce una marcada heterogeneidad espacial y temporal en los patrones de precipitación, con fuertes gradientes en distancias relativamente cortas (Lavado-Casimiro Espinoza, 2014).

A escala sinóptica, la principal temporada de lluvias —el verano austral, de diciembre a marzo— está controlada por el Sistema Monzónico de América del Sur (SAMS). La posición de la Zona de Convergencia del Atlántico Sur (ZCAS) y el transporte de humedad desde el Atlántico tropical hacia la Amazonía determinan la magnitud de las lluvias, especialmente en la vertiente oriental de los Andes, donde el ascenso orográfico genera precipitaciones intensas. Por el contrario, la vertiente occidental presenta una marcada sombra pluviométrica y condiciones mucho más secas (Garreaud et al., 2009; Silva et al., 2020).

La variabilidad interanual de estas lluvias está influenciada por fenómenos de gran escala como El Niño–Oscilación del Sur (ENOS), que modula la circulación regional y altera los patrones de humedad y precipitación (Lavado-Casimiro et al., 2013). No obstante, la representación de estos procesos se ve limitada por la baja densidad de estaciones meteorológicas en zonas andinas y

amazónicas, dificultando la caracterización de la precipitación en regiones de topografía compleja (Aybar et al., 2017).

Ante estas limitaciones, el uso de productos satelitales e híbridos, así como de reanálisis globales, se ha vuelto fundamental para complementar las observaciones in situ. En el Perú, destacan PISCOp, CHIRPS y el reanálisis ERA5, ampliamente utilizados en estudios climatológicos por su cobertura espacial continua y su frecuencia temporal uniforme. Sin embargo, su aplicación requiere una validación rigurosa frente a registros locales, considerando su desempeño estadístico, sesgos sistemáticos y capacidad para representar eventos extremos (Salas et al., 2023).

Además, la fragmentación y discontinuidad de los registros observados exige la aplicación de técnicas de completado de series, como regresión múltiple o métodos basados en relaciones espaciales entre estaciones (Romero Casimiro, 2015), que permiten reconstruir series pluviométricas más consistentes.

En este contexto, la presente investigación integra datos observacionales del SENAMHI con los productos CHIRPS y ERA5 para analizar la variación espacio-temporal de la precipitación en la Sierra y Selva del Perú durante 1981–2014. Asimismo, se implementa un modelo de regresión para estimar valores faltantes y mejorar la continuidad de las series, aportando una visión más completa de la variabilidad pluviométrica en regiones de topografía compleja.

Author for correspondence:
Cite this article:

2. Objetivos

2.1. Objetivo General

Caracterizar la variabilidad espacio–temporal de la precipitación en los Andes (Sierra) y la Amazonía (Selva) del Perú durante el período 1981–2014, integrando información observacional (SENAMHI), satelital (CHIRPS) y de reanálisis (ERA5). Asimismo, evaluar la calidad de estas fuentes y desarrollar modelos estadísticos, de aprendizaje automático y redes neuronales (LSTM) para el pronóstico de la precipitación mensual a 12 meses.

2.2. Objetivos Específicos

1. Realizar la limpieza de datos y aplicar la regla 3/5 para la completación de información faltante con *PISCO*, garantizando la homogeneización de las series.
2. Convertir las series diarias a escala mensual y generar representaciones estadísticas (series temporales, histogramas y boxplots) para su caracterización inicial.
3. Evaluar la consistencia de *CHIRPS* y *ERA5* frente a las observaciones del *SENAMHI* mediante el análisis de una matriz de correlación mensual.
4. Implementar modelos predictivos para el pronóstico mensual de precipitación, incluyendo regresión lineal múltiple, *Random Forest* y redes neuronales *LSTM*, empleando como predictores los productos *CHIRPS* y *ERA5*.
5. Comparar el desempeño de los modelos mediante métricas como MAE, RMSE y R^2 , evaluando su capacidad para mejorar la continuidad de las series del *SENAMHI* y pronosticar la precipitación a 12 meses.

3. Metodología

3.1. Zona de Estudio

El estudio se enfoca en cuatro zonas representativas del gradiente altitudinal peruano:

- **Valle Interandino:** Región ubicada entre los 2,000 y 3,800 m s. n. m.
- **Sierra Alta:** Comprende altitudes entre 3,800 y 4,800 m s. n. m.
- **Selva Alta:** Situada entre los 400 y 1,000 m s. n. m.
- **Selva Baja:** Abarca altitudes menores a 400 m s. n. m.

3.2. Estaciones para el análisis

Se seleccionaron cuatro estaciones del SENAMHI representativas de las zonas de estudio (Cuadro 1 y Figura 1).




Figure 1. Mapa de las cuatro estaciones utilizadas en el análisis.

Table 1. Ubicación de las estaciones meteorológicas consideradas en el estudio.

Estación	Lat (°)	Lon (°)	Alt (m)	Región
JAÚJA	-11.78	-75.48	3363	Valle Interandino
HUANCANÉ	-15.20	-69.75	3842	Sierra Alta
PUCALLPA	-6.45	-75.84	162	Selva Baja
TINGO MARÍA	-9.31	-76.00	657	Selva Alta

3.3. Datos Utilizados

3.3.1. CHIRPS

CHIRPS (Climate Hazards Group InfraRed Precipitation with Station data) es un conjunto de datos desarrollado por la *University of California, Santa Barbara*. Combina estimaciones satelitales infrarrojas con datos de estaciones meteorológicas, abarcando la franja cuasi-global entre 50°S y 50°N. Ofrece resolución diaria de aproximadamente 5 km y está diseñado para el monitoreo de sequías y eventos de precipitación extrema (Funk et al., 2015). En el Perú, **PISCO** utiliza CHIRPS como una de sus fuentes principales para la construcción de su grilla nacional.

3.3.2. ERA5

ERA5 es el producto de reanálisis de quinta generación del *European Centre for Medium-Range Weather Forecasts* (ECMWF). Proporciona estimaciones consistentes espacial y temporalmente de múltiples variables atmosféricas, utilizando un sistema de asimilación de datos de última generación. Ofrece una resolución espacial de ~31 km y resolución temporal horaria, con cobertura desde 1950 hasta la actualidad. ERA5 integra observaciones satelitales, radiosondeos, boyas, sensores remotos y datos de superficie para reconstruir el estado atmosférico global (Hersbach et al., 2020). Gracias a su continuidad y homogeneidad, es ampliamente empleado para estudios climáticos y validación de datos observacionales en regiones con escasez de estaciones.

3.4. Regla de 3/5

La Regla 3/5 es un criterio utilizado para evaluar la validez climatológica de un mes. Un mes se considera válido si:

- tiene **menos de cinco días faltantes** en total, y




Figure 2. Flujograma del procedimiento metodológico.

- no presenta **más de tres días consecutivos** sin datos.

Si alguna de estas condiciones no se cumple, el mes se excluye o se completa mediante métodos de imputación, evitando sesgos por registros incompletos (Anderson & Gough, 2018).

3.5. Métricas de Error

3.5.1. Correlación de Pearson

La correlación de Pearson (r) cuantifica la relación lineal entre dos variables continuas, tomando valores entre -1 y 1 .

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

3.5.2. Raíz del Error Cuadrático Medio (RMSE)

El RMSE mide la magnitud promedio del error entre valores observados y estimados:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (P_i - O_i)^2}$$

3.5.3. Sesgo Medio (BIAS)

El sesgo medio indica si un modelo tiende a sobrestimar o subestimar los valores observados:

$$BIAS = \frac{1}{n} \sum_{i=1}^n (P_i - O_i)$$

Un BIAS positivo implica sobreestimación; uno negativo, subestimación sistemática.

3.6. Flujo de Procesamiento de Datos

El procesamiento integró información proveniente de **ERA5**, **CHIRPS** y **registros observacionales del SENAMHI**. A continuación, se describen las etapas principales del flujo metodológico mostrado en la Figura 2.

3.6.1. Descarga y Preparación Inicial

Los datos diarios de precipitación de **CHIRPS** fueron descargados en formato NetCDF mediante `pooch`. Los datos horarios de **ERA5**

se agregaron posteriormente a escala diaria. Los registros crudos del **SENAMHI** (formato .txt) fueron recopilados para su posterior control de calidad.

3.6.2. Exploración Inicial de SENAMHI

Mediante `Pandas` y `Matplotlib` se identificaron valores atípicos, datos faltantes y patrones inconsistentes en las series crudas.

3.6.3. Control de Calidad y Completación

Se aplicó la **Regla 3/5** para filtrar meses incompletos. Luego, se realizó la **completación de datos** utilizando las series mensuales **PISCOp**, obteniendo el dataset final `datos_completos.Datos_tp2.csv`.

3.6.4. Mensualización y Homogeneización

Los datos diarios de ERA5, CHIRPS y SENAMHI-PISCOp fueron agregados a escala **mensual** para generar series comparables destinadas al análisis estadístico y modelado.

3.6.5. Visualización y Análisis Exploratorio

Con las series mensualizadas se generaron:

- series temporales de precipitación,
- histogramas,
- diagramas de caja,
- mapas estacionales CHIRPS mediante `Xarray`.

3.6.6. Correlación entre Datasets

Se construyó una **matriz de correlación** entre las series mensualizadas de ERA5, CHIRPS y SENAMHI-PISCOp para evaluar el grado de correspondencia entre productos satelitales, reanálisis y observaciones.

3.7. Modelos Predictivos

Se implementaron tres modelos para la predicción de precipitación mensual: **Regresión Lineal Múltiple**, **Random Forest** y una **Red Neuronal LSTM**. Este enfoque permitió comparar métodos estadísticos tradicionales, técnicas de aprendizaje automático y modelos basados en dependencias temporales.

3.7.1. Regresión Lineal Múltiple

Utilizada como modelo base por su simplicidad e interpretabilidad. Permite estimar relaciones lineales entre la precipitación mensual y los predictores derivados de CHIRPS y ERA5.

3.7.2. Random Forest

Algoritmo basado en múltiples árboles de decisión, capaz de capturar relaciones no lineales y reducir el sobreajuste mediante muestreo aleatorio de predictores y observaciones.

3.7.3. Red Neuronal LSTM

Las redes **LSTM** permiten modelar dependencias temporales de largo plazo en series de tiempo. En este estudio se entrenaron con secuencias históricas mensuales de CHIRPS y ERA5 para generar pronósticos a 12 meses.

Los tres modelos fueron entrenados con datos del periodo 1981–2014 y utilizados para pronosticar los 12 meses posteriores.

4. Resultados y Discusión

4.1. Series Temporales Mensuales




Figure 3. Serie temporal mensual de precipitación para los registros observacionales del SENAMHI.

4.1.1. Comparación de la Mediana de Precipitación

La mediana constituye un indicador robusto de la precipitación típica mensual. Las diferencias observadas entre las tres fuentes pueden resumirse en la Tabla 2.

Table 2. Valores de mediana de precipitación mensual (mm/mes) para cada estación y conjunto de datos.

Estación	ERA5	SENAMHI	CHIRPS
Tingo María	134.37	248.93	203.19
Pucallpa	181.57	188.07	114.72
Huancané	236.87	51.67	50.08
Jauja	146.11	53.03	56.26

Series Mensuales — CHIRPS




Figure 4. Serie temporal mensual de precipitación derivada del producto satelital CHIRPS.

Series Mensuales — ERA5




Figure 5. Serie temporal mensual de precipitación a partir del reanálisis ERA5.

Para las estaciones de la región amazónica (Tingo María y Pucallpa), los datos de SENAMHI presentan medianas más altas que las estimaciones de ERA5 y CHIRPS, lo que sugiere una subestimación de la precipitación por parte de los productos de reanálisis y satelitales. En cambio, para las estaciones andinas (Huancané y Jauja), ERA5 muestra medianas considerablemente mayores que SENAMHI y CHIRPS, lo que indica una sobreestimación sistemática de la precipitación en zonas altoandinas.

4.1.2. Discrepancias en la Amplitud y en los Eventos Extremos

Además de las diferencias en la mediana, también se observan contrastes importantes en la amplitud y magnitud de los eventos extremos:

- En la estación amazónica de Tingo María, los datos de SENAMHI muestran picos que superan los 700 mm/mes, mientras que ERA5 y CHIRPS presentan máximos alrededor de 350–550 mm/mes. Esto sugiere que los productos de modelación (ERA5) y satelitales (CHIRPS) podrían estar suavizando los eventos extremos.
- En las estaciones andinas, particularmente Huancané, ERA5 alcanza valores máximos cercanos a los 500 mm/mes, lo cual contrasta fuertemente con los registros observados, mucho más

bajos. Esto se interpreta como una sobreestimación sistemática del reanálisis en regiones con topografía compleja.

4.2. Distribución y Variabilidad

4.2.1. Diagramas de Caja




Figure 6. Diagrama de caja de la precipitación mensual observada (SENAMHI).




Figure 7. Diagrama de caja de la precipitación mensual según CHIRPS.

4.2.2. Análisis de Boxplots de Precipitación Mensual

Los diagramas de caja permiten comparar de manera directa la dispersión, asimetría y posición de los cuartiles de la precipitación mensual proveniente de SENAMHI, CHIRPS y ERA5. A diferencia de los histogramas, los boxplots resaltan la estructura estadística de la distribución, facilitando la identificación de diferencias entre fuentes y regiones.

Cuartiles de precipitación. La Tabla 3 presenta los valores de Q1, mediana y Q3 para cada estación y fuente, junto con el rango intercuartil (IQR). En general, SENAMHI muestra los




Figure 8. Diagrama de caja de la precipitación mensual estimada por ERA5.

IQR más amplios, indicando una mayor variabilidad mensual, especialmente en las estaciones amazónicas.

Table 3. Cuartiles de precipitación mensual (mm/mes) por estación y fuente.

Estación	Fuente	Q1	Q2	Q3	IQR
Huancané	SENAMHI	15.90	51.67	108.79	92.89
	CHIRPS	20.99	50.08	103.97	82.98
	ERA5	154.38	236.87	332.54	178.16
Jauja	SENAMHI	12.87	53.03	93.59	80.72
	CHIRPS	13.54	56.26	98.84	85.30
	ERA5	91.08	146.11	217.69	126.61
Pucallpa	SENAMHI	110.66	188.07	269.73	159.07
	CHIRPS	85.84	114.72	150.57	64.73
	ERA5	109.05	181.57	236.89	127.84
Tingo María	SENAMHI	150.35	248.93	371.57	221.22
	CHIRPS	102.15	203.19	296.28	194.13
	ERA5	74.40	134.37	188.28	113.88

Estaciones andinas: Huancané y Jauja. En ambas estaciones andinas, las distribuciones de SENAMHI y CHIRPS muestran una alta similitud. Los valores de Q1 se encuentran por debajo de 21 mm/mes, reflejando la marcada estación seca. SENAMHI presenta un IQR ligeramente mayor, particularmente en Huancané, lo que indica una mayor variabilidad de las precipitaciones en los meses húmedos.

El comportamiento de ERA5 presenta discrepancias importantes. Los boxplots proporcionados muestran medianas mucho menores (37.14 y 49.81 mm), lo cual contrasta con los valores altos observados en las series temporales e histogramas. Si los boxplots de ERA5 son correctos, ello sugeriría una subestimación considerable de la precipitación en la región andina; si los histogramas son los correctos, entonces ERA5 estaría sobreestimando fuertemente la precipitación. En ambos casos, la coherencia entre SENAMHI y CHIRPS sugiere que estas fuentes representan mejor la estacionalidad andina.

Estaciones amazónicas: Pucallpa y Tingo María. En la región amazónica se observan diferencias más marcadas entre las fuentes. SENAMHI presenta medianas significativamente superiores y los IQR más amplios, lo que indica una mayor capacidad para capturar eventos húmedos intensos y una variabilidad mensual más alta. En Pucallpa, por ejemplo, la mediana de SENAMHI supera ampliamente a las de CHIRPS y ERA5, cuyo comportamiento es prácticamente idéntico.

En Tingo María se observa un patrón similar: SENAMHI registra la mayor precipitación y la dispersión más amplia. CHIRPS y ERA5 muestran distribuciones muy parecidas, lo que podría reflejar una limitación compartida para representar la variabilidad mensual amazónica, especialmente los eventos extremos.

4.2.3. Histogramas de Frecuencia




Figure 9. Histogramas de precipitación mensual para los registros SENAMHI.




Figure 10. Histogramas de precipitación mensual derivados de CHIRPS.




Figure 11. Histogramas de precipitación mensual provenientes de ERA5.

4.2.4. Estaciones Andinas: Huancané y Jauja

La diferencia entre las fuentes es más notoria en las estaciones ubicadas en la región andina, donde la precipitación presenta una marcada estacionalidad.

- **SENAMHI:** En ambas estaciones, la distribución es **altamente sesgada a la derecha**, con la mayor frecuencia concentrada cerca de valores muy bajos, incluso cercanos a cero. Las medianas son de 51.67 mm (Huancané) y 53.03 mm (Jauja).
- **CHIRPS:** Presenta una distribución muy similar a SENAMHI, también fuertemente sesgada positivamente, con medianas de 50.08 mm (Huancané) y 56.26 mm (Jauja).
- **ERA5:** Exhibe distribuciones **casi simétricas o incluso bimodales**, con frecuencias máximas alejadas de los valores bajos. Las medianas (236.87 mm en Huancané y 146.11 mm en Jauja) confirman una clara **sobreestimación de la precipitación** mensual en ambas estaciones andinas.

Estos resultados evidencian que tanto SENAMHI como CHIRPS reflejan adecuadamente la estructura climática de la región andina —caracterizada por largos periodos secos—, mientras que ERA5 no reproduce esta característica fundamental y tiende a suavizar o eliminar la estación seca.

4.2.5. Estaciones Amazónicas: Pucallpa y Tingo María

En la región amazónica, donde el régimen de lluvias es más continuo, las diferencias entre las fuentes son menos extremas.

- **SENAMHI:** Muestra distribuciones sesgadas a la derecha con medianas de 188.07 mm (Pucallpa) y 248.93 mm (Tingo María). Posee colas derechas más largas, capturando eventos extremos.
- **CHIRPS:** En Pucallpa, el histograma está desplazado hacia la izquierda, con una moda alrededor de 100 mm y una mediana de 114.72 mm, indicando **subestimación**. En Tingo María presenta cierta bimodalidad.
- **ERA5:** En Pucallpa, su distribución es similar a SENAMHI, lo que sugiere buen desempeño. En Tingo María, sin embargo, la distribución se desvía a la izquierda, con mediana de 134.37 mm, confirmando la **subestimación de la precipitación**.

En conjunto, SENAMHI es la única fuente que captura completamente la magnitud de los eventos extremos en la Amazonía, mientras que CHIRPS tiende a subestimar en Pucallpa y ERA5 subestima en Tingo María.

Este análisis confirma que las estaciones andinas presentan distribuciones típicas de climas con estación seca prolongada (distribuciones Gamma o log-normales), reproducidas adecuadamente por SENAMHI y CHIRPS, pero **no por ERA5**. En contraste, las estaciones amazónicas muestran distribuciones amplias y con mayor variabilidad, donde SENAMHI refleja mejor los eventos extremos.

4.3. Correlación Entre Datasets




Figure 12. Matriz de correlación entre SENAMHI, CHIRPS y ERA5 para precipitación mensual.

Table 4. Correlación de Pearson (r) entre fuentes en estaciones andinas.

Correlación	Huancané	Jauja
SENAMHI vs. CHIRPS	0.92	0.96
SENAMHI vs. ERA5	0.86	0.91
CHIRPS vs. ERA5	0.88	0.91

Estaciones Andinas: Huancané y Jauja. En Huancané y Jauja, todas las fuentes presentan correlaciones altas ($r = 0.86$ – 0.96), indicando que aunque ERA5 sobreestima la magnitud de la precipitación, los patrones temporales de meses secos y húmedos están correctamente capturados. La correlación más alta se observa entre SENAMHI y CHIRPS, validando la buena reproducción de la señal temporal por el producto satelital.

Table 5. Correlación de Pearson (r) entre fuentes en estaciones amazónicas.

Correlación	Pucallpa	Tingo María
SENAMHI vs. CHIRPS	0.67	0.88
SENAMHI vs. ERA5	0.70	0.84
CHIRPS vs. ERA5	0.61	0.85

Estaciones Amazónicas: Pucallpa y Tingo María. En Tingo María, las correlaciones son fuertes ($r = 0.84$ – 0.88), lo que indica que los productos estiman correctamente la variabilidad temporal a pesar de diferencias en magnitud. En Pucallpa, los valores de r son bajos (0.61 – 0.70), reflejando la dificultad de CHIRPS y ERA5 para replicar tanto la magnitud como la señal temporal de SENAMHI.

4.4. Pronósticos a 12 Meses




Figure 13. Pronóstico de precipitación mensual a 12 meses utilizando Random Forest.




Figure 14. Pronóstico de precipitación mensual a 12 meses mediante Regresión Lineal Múltiple.

Estaciones de la Sierra: Huancané y Jauja. En las estaciones ubicadas en la región andina, los modelos estadísticos tradicionales (Regresión Lineal AR y Random Forest AR) presentan el mejor desempeño, asociado a la presencia de una estacionalidad bien definida y una menor variabilidad intraanual de la precipitación.




Figure 15. Pronóstico de precipitación mensual a 12 meses mediante Redes Neuronales LSTM.

Table 6. Comparativa del coeficiente de determinación (R^2) por estación y modelo.

Estación	Regresión Lineal AR	Random Forest AR	LSTM
Huancané	0.796	0.432	0.797
Jauja	0.899	0.910	0.828
Pucallpa	0.548	0.456	0.392
Tingo María	0.784	0.718	0.731

- **Jauja** alcanza el mayor nivel de precisión mediante el modelo **Random Forest AR** ($R^2 = 0.910$), el valor más alto obtenido en todo el estudio. Este resultado sugiere la presencia de relaciones no lineales entre los retardos temporales de la precipitación que son capturadas de manera eficiente por algoritmos basados en árboles.
- **Huancané** representa un caso en el cual la **Regresión Lineal AR** supera a los demás enfoques ($R^2 = 0.796$), indicando que la dinámica de la precipitación está dominada por una estacionalidad fuerte y relaciones aproximadamente lineales con sus valores pasados. En este contexto, modelos más complejos como Random Forest o LSTM no aportan mejoras significativas y pueden verse afectados por sobreajuste.

Estaciones de la Selva/Amazonía: Pucallpa y Tingo María. En las estaciones amazónicas, caracterizadas por una mayor variabilidad climática y un régimen de precipitación más irregular, los modelos predictivos presentan un desempeño más limitado en general. A diferencia de lo observado en la Sierra, los enfoques basados en aprendizaje profundo no logran superar a los modelos estadísticos tradicionales.

- **Pucallpa:** La **Regresión Lineal AR** obtiene el mejor desempeño ($R^2 = 0.548$), superando tanto a Random Forest ($R^2 = 0.456$) como al modelo LSTM ($R^2 = 0.393$). Este resultado sugiere que, para esta estación, la precipitación mantiene una relación más estable con sus valores pasados que puede ser capturada eficientemente por modelos lineales, mientras que la alta variabilidad limita el desempeño de modelos más complejos.
- **Tingo María:** Se observa un comportamiento similar, donde la **Regresión Lineal AR** vuelve a ser el modelo más preciso ($R^2 = 0.784$), seguida por Random Forest ($R^2 = 0.718$) y LSTM ($R^2 = 0.685$). Esto indica que, pese a tratarse de una región

amazónica, la estructura temporal de la serie favorece modelos autoregresivos simples frente a redes neuronales profundas.

Análisis cualitativo de la estacionalidad. Si bien métricas como el coeficiente de determinación (R^2) indican un mejor desempeño numérico de la Regresión Lineal AR en varias estaciones, el análisis visual de los pronósticos evidencia diferencias relevantes en la estructura de las predicciones. En el horizonte de forecast, los modelos clásicos tienden a estabilizarse rápidamente o a presentar oscilaciones de baja amplitud, reflejando una convergencia hacia la media y una pérdida de la señal estacional.

En contraste, el modelo LSTM logra preservar la forma cíclica de la precipitación, reproduciendo de manera más realista la alternancia entre temporadas húmedas y secas. Esta capacidad se explica por su arquitectura de memoria de largo plazo, que permite capturar patrones estacionales persistentes. En consecuencia, aunque el LSTM no siempre presenta los mayores valores de R^2 , su desempeño cualitativo resulta más coherente con la dinámica hidrológica, lo que lo convierte en una herramienta complementaria valiosa cuando el objetivo es representar el ciclo climático de forma realista.

5. Conclusiones

A partir del análisis de la variabilidad espacio-temporal de la precipitación en las regiones de Sierra y Selva del Perú durante el período 1981–2014, y tras la implementación de modelos predictivos, se derivan las siguientes conclusiones principales:

- **Validación y sesgos de las fuentes de datos:**El estudio confirma la utilidad de los productos CHIRPS y ERA5 para complementar los registros observacionales del SENAMHI en zonas de difícil acceso. Sin embargo, se identificaron sesgos sistemáticos dependientes de la región: ERA5 sobreestima significativamente la precipitación en la Sierra y no reproduce adecuadamente su estacionalidad seca, mientras que tanto CHIRPS como ERA5 subestiman la magnitud de los eventos extremos en la Selva. Esto implica que no existe una fuente única óptima; la elección debe basarse en la región de estudio y el objetivo específico del análisis.

Desempeño diferencial de los modelos predictivos según la región:

- **En la Sierra:**Los modelos más simples, como la Regresión Lineal AR y Random Forest AR, mostraron un alto desempeño (R^2 de hasta 0.910 en Jauja), aprovechando la estacionalidad bien definida de la zona. La Regresión Lineal AR destacó por su robustez y ausencia de sobreajuste, siendo recomendable para predicciones estables en esta región.
- **En la Selva:** La mayor variabilidad e irregularidad de la precipitación limitó la precisión de todos los modelos. La Regresión Lineal AR fue el enfoque más consistente, aunque con valores de R^2 moderados (ej. 0.548 en Pucallpa). Los modelos más complejos, como LSTM, no superaron significativamente a los métodos tradicionales en términos numéricos, pero demostraron una ventaja cualitativa al preservar mejor la ciclicidad estacional en los pronósticos a largo plazo.

- **Implicaciones para la gestión hídrica y climática:** Los resultados proporcionan herramientas para mejorar el monitoreo y la predicción de la precipitación en regiones con topografía compleja y escasez de estaciones. La capacidad de los modelos calibrados para operar con datos satelitales y de reanálisis permite la generación de información continua y fiable, útil para la gestión proactiva de recursos hídricos, la identificación temprana de sequías en la Sierra y la vigilancia de eventos extremos en la Selva. Esto contribuye a una planificación climática más informada y adaptativa en la región andino-amazónica.

El código fuente y los materiales complementarios utilizados en este estudio se encuentran disponibles públicamente en el repositorio de GitHub “*TECNICAS-DE-PROGRAMACIÓN*”, accesible en <https://github.com/brenda-nsz/TECNICAS-DE-PROGRAMACION>.

6. Referencias bibliográficas

References

- [1] Aybar, C., Lavado-Casimiro, W., Huerta, A., Fernández, C., Vega, F., Sabino, E., & Felipe-Obando, O. (2017). *Uso del producto grilado "PISCO" de precipitación en estudios, investigaciones y sistemas operacionales de monitoreo y pronóstico hidrometeorológico (Nota Técnica No. 001)*. SENAMHI. <https://www.senamhi.gob.pe/load/file/01402SENA-8.pdf>
- [2] Anderson, C. I., & Gough, W. A. (2018). Accounting for missing data in monthly temperature series: Testing rule-of-thumb omission of months with missing values. *International Journal of Climatology*, 38(13), 4990-5002. <https://doi.org/10.1002/joc.5801>
- [3] Castro, A., Davila, C., Laura, W., Cubas, F., Avalos, G., López Ocaña, C., Villena, D., Valdez, M., Urbiola, J., Trebejo, I., Menis, L., & Marín, D. (2021). *Climas del Perú: Mapa de clasificación climática nacional*. SENAMHI. <https://www.senamhi.gob.pe/load/file/01404SENA-4.pdf>
- [4] Climate Hazards Center UC Santa Barbara. (s.f.). *CHIRPS: Climate Hazards group InfraRed Precipitation with Station data*. <https://data.chc.ucsb.edu/products/CHIRPS-2.0/global.daily/netcdf/p25/>
- [5] Climate Hazards Center UC Santa Barbara. (s.f.). *CHIRPS FAQ*. https://wiki.chc.ucsb.edu/CHIRPS_FAQ
- [6] Funk, C., Peterson, P., Landsfeld, M., Pedreros, D., Verdin, J., Shukla, S., Husak, G., Rowland, J., Harrison, L., Hoell, A., & Michaelsen, J. (2015). The climate hazards infrared precipitation with stations—a new environmental record for monitoring extremes. *Scientific Data*, 2, 150066. <https://www.nature.com/articles/sdata201566>
- [7] Huffman, G. J., Bolvin, D. T., Braithwaite, D., Hsu, K., Joyce, R., Kidd, C., Nelkin, E. J., Sorooshian, S., Tan, J., & Xie, P. (2020). *Integrated Multi-satellite Retrievals for GPM (IMERG): Algorithm Theoretical Basis Document (ATBD)*, Version 06.3. NASA. https://gpm.nasa.gov/sites/default/files/2020-05/IMERG_ATBD_V06.3.pdf
- [8] International Research Institute for Climate and Society. (2020). *SENAHMI HSR PISCO*. The Columbia Climate School, Columbia University. <https://iridl.ldeo.columbia.edu/SOURCES/.SENAHMI/.HSR/.PISCO/index.html?Set-Language=es>
- [9] Lavado-Casimiro, W. S., & Espinoza, J. C. (2014). Impactos de El Niño y La Niña en las lluvias del Perú (1965–2007). *Revista Brasileira de Meteorologia*, 29(2), 171–182. <https://doi.org/10.1590/S0102-77862014000200003>
- [10] Lavado-Casimiro, W. S., Felipe-Obando, O., & Silva, Y. (2013). Mejoramiento de la estimación de la precipitación en el Perú usando datos de satélite y métodos de interpolación. *Revista de la Asociación Española de Climatología*, 12, 447–457.
- [11] Llaccharimay Sotelo, F. A. (2025). *Validación de estimaciones satelitales y terrestres de precipitación para Apurímac, 2000–2019* [Tesis de título profesional, Universidad Nacional José María Arguedas].
- [12] Millán Arancibia, C. (2023). *Conjunto de datos de precipitación grilada diaria de alta resolución para la vertiente del Pacífico en Perú mediante una Interpolación Espacial Random Forest: Estudio final*. SENAMHI. <https://www.senamhi.gob.pe/load/file/01401SENA-105.pdf>
- [13] Ministerio del Ambiente del Perú. (2019). *Tercera Comunicación Nacional del Perú a la CMNUCC*. Lima, Perú: MINAM.
- [14] NASA Goddard Earth Sciences Data and Information Services Center (GES DISC). (2023). *Giovanni — herramienta de visualización y descarga de datos (GPM IMERG)*. <https://giovanni.gsfc.nasa.gov/giovanni/>
- [15] Nóbrega, J. N. da, Santos, C. A. C. dos, Gomes, O. M., Bezerra, B. G., & Brito, J. I. B. de. (2014). Eventos extremos de precipitación en Paraíba y su relación con la TSM. *Revista Brasileira de Meteorologia*, 29(2). <https://doi.org/10.1590/S0102-77862014000200005>
- [16] Luna Romero, A. E., Luna Romero, A. E., Lavado Casimiro, W. S. (2015). *Evaluación de métodos hidrológicos para la completación de datos faltantes de precipitación en estaciones de la cuenca Jequetepeque*. *Revista Tecnológica - ESPOL*, 28(3). <https://rte.espol.edu.ec/index.php/tecnologica/article/view/400>
- [17] Salas-Choquehuanca, A. J., Rosales-Solorzano, E. R., Alvarez-Montalván, C. E., & Asunción-Córdova, R. M. (2020). Comparación del producto GPM IMERG y PISCO en Madre de Dios. *Revista de Estudios Científicos*, 3(2). <https://ceprosimad.com/index.php/rec/article/view/99/20>
- [18] Salas Choquehuanca, A. J. (2022). *Validación de datos GPM en Madre de Dios (2010–2019)* [Tesis de pregrado, UNAMAD]. <https://repositorio.unamad.edu.pe/handle/20.500.14070/828>
- [19] Servicio Nacional de Meteorología e Hidrología del Perú. (2018). *Caracterización climática del Perú*. Lima, Perú: SENAMHI.
- [20] SENAMHI (2019). *Caracterización climática de la Sierra peruana*. <https://www.senamhi.gob.pe/?p=publicaciones>
- [21] Túpac Yupanqui Vélez, R. (2015). *Validación de datos CHIRPS para monitoreo seco/húmedo en Perú*. SENAMHI. <https://sigrid.cenepred.gob.pe/sigridv3/documento/1917>